Классификация

Будем решать задачу бинарной классификации, то есть классификации на два класса.

Пример: классификация больных

- есть данные о пациентах
- хочется построить модель предсказания болен человек или здоров

Два типа данных

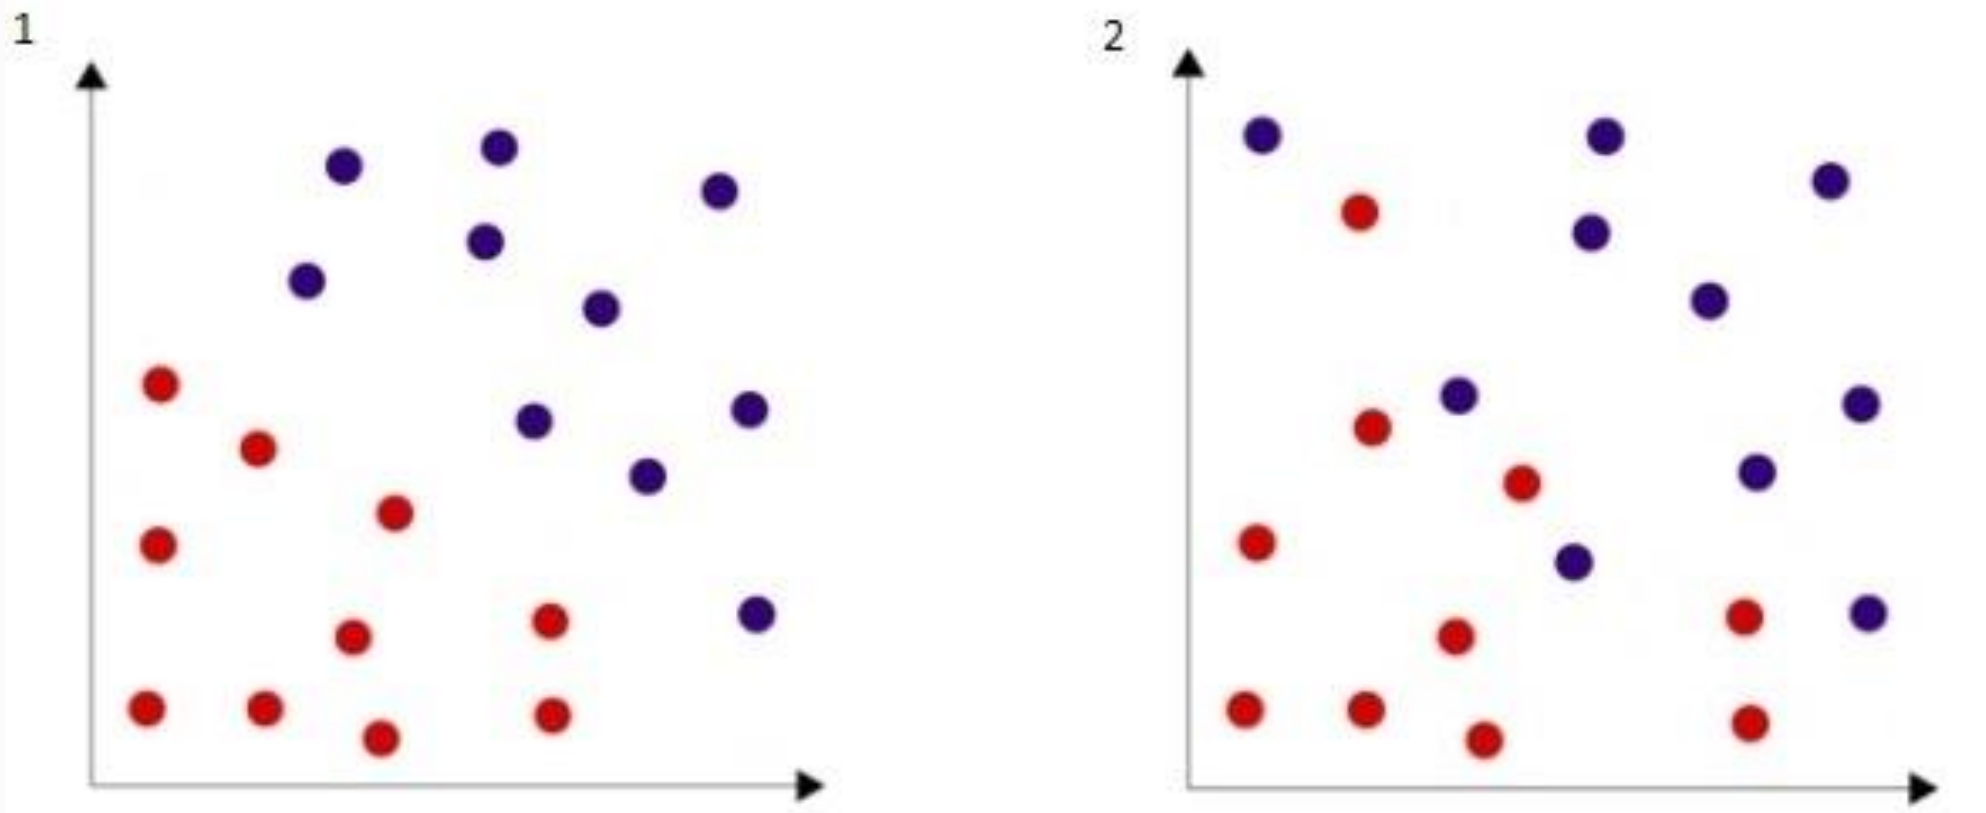

Первая выборка

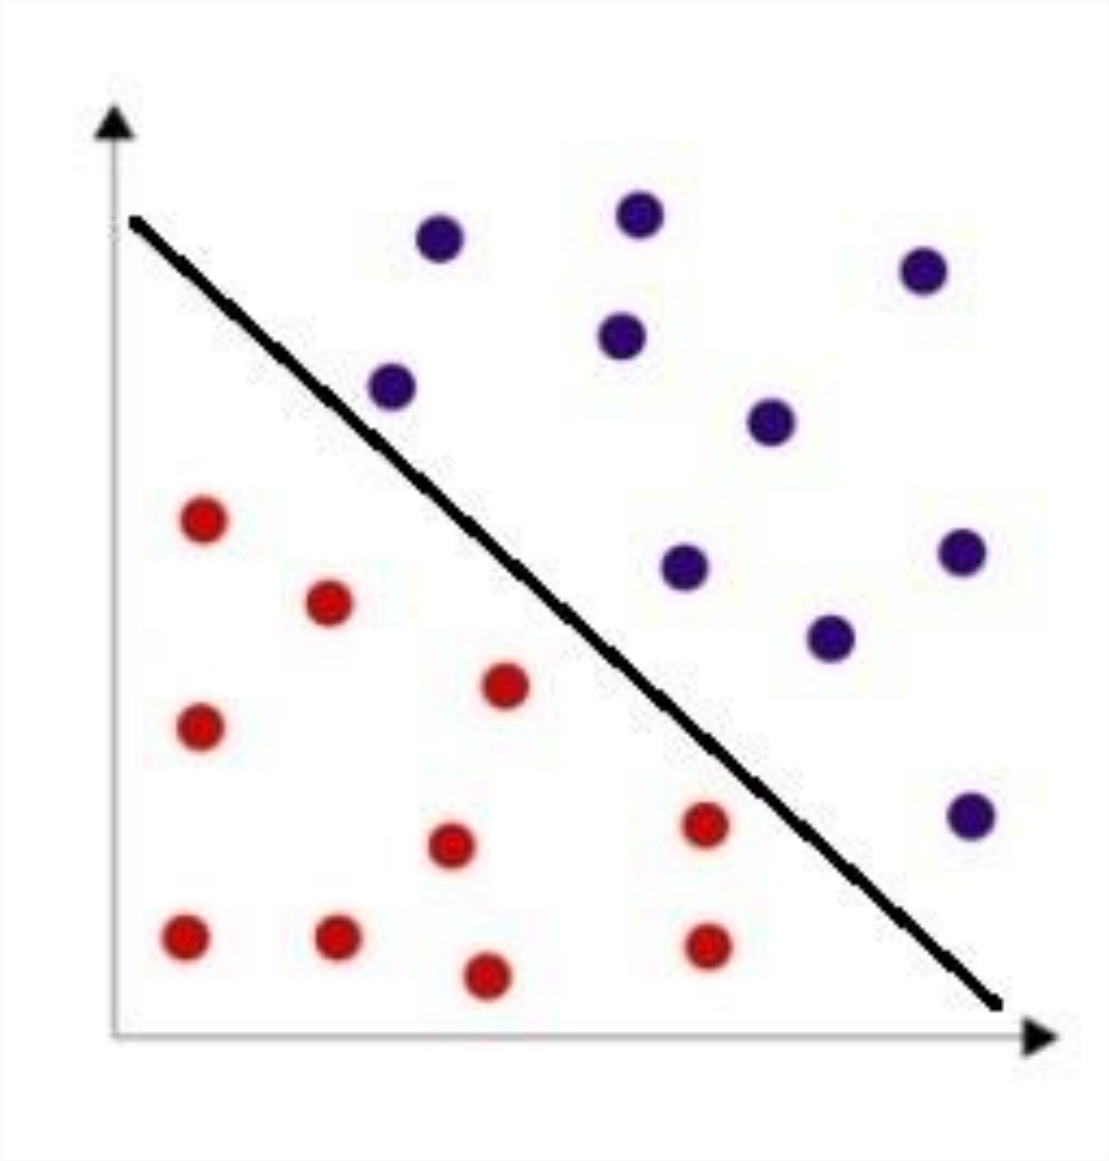

Линейно разделимая выборка

Вторая выборка

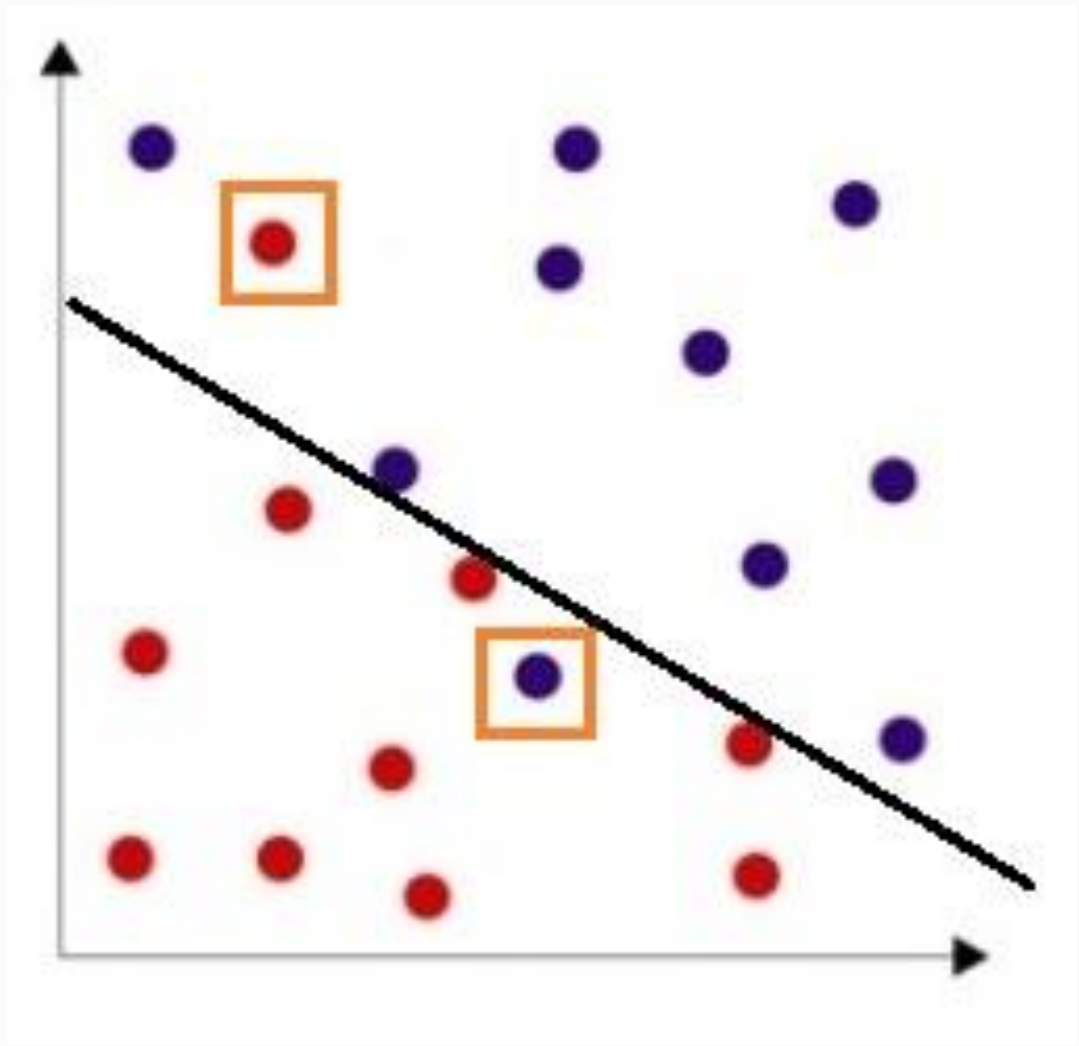

Не является линейно разделимой

Многомерный случай

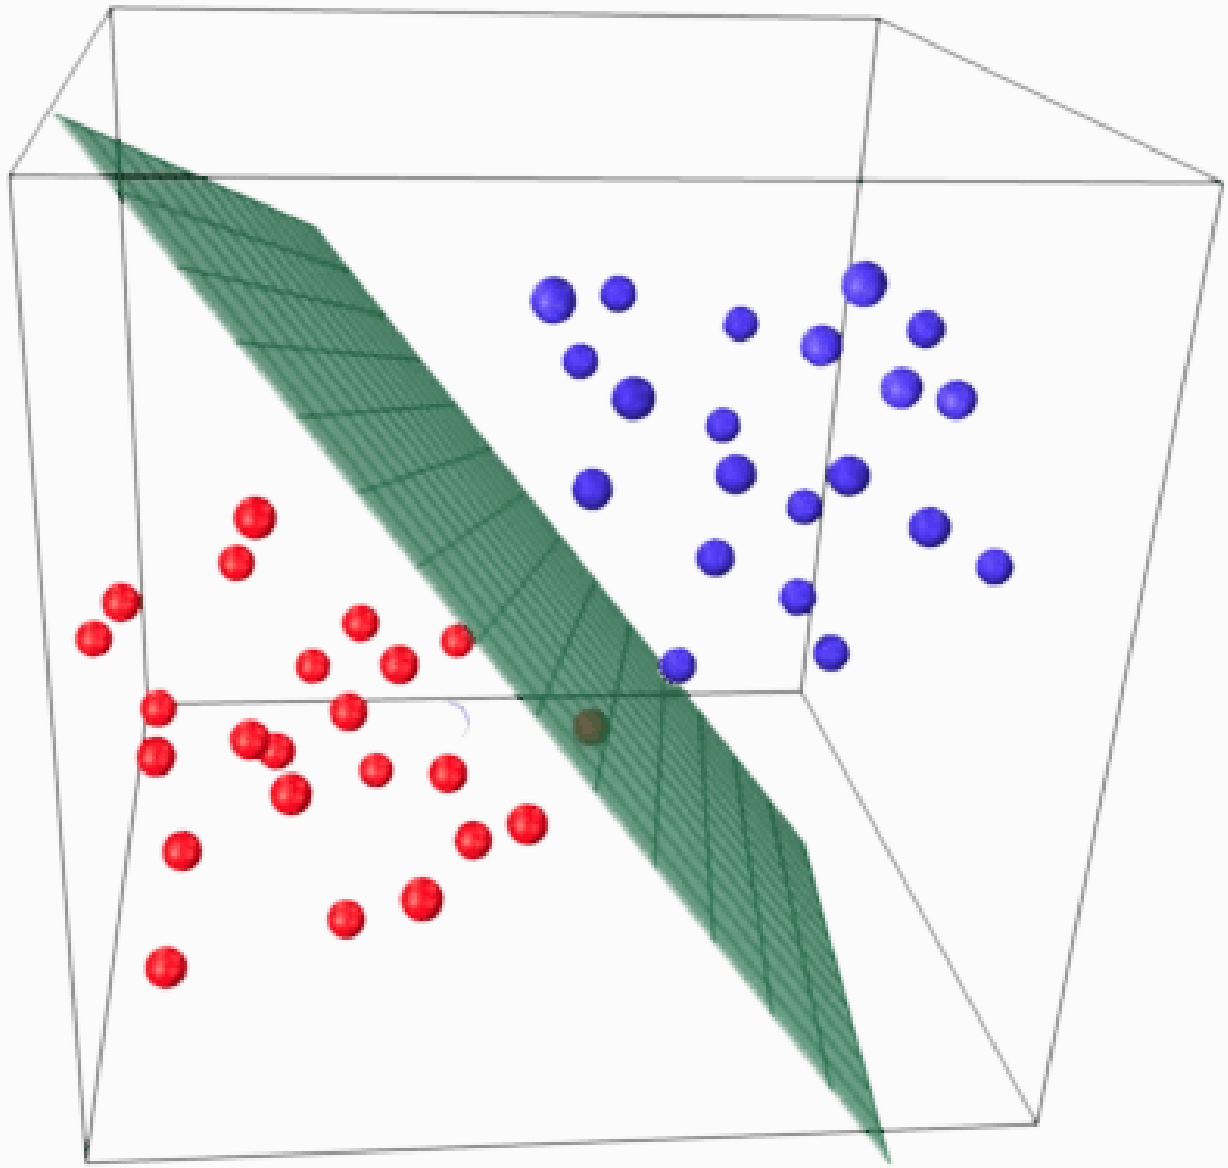

Линейно разделимая выборка

Формула линейной регрессии

$$a(x) = w_0 + w_1 x_1 + w_2 x_2 + \cdots + w_d x_d,$$

- $a(x)$ - предсказание модели
- $x_1, x_2, \ldots$ - признаки объекта
- $w_0, w_1, w_2, \ldots$ - веса модели

Формула линейной регрессии

$$a(x) = (w, x)$$

Бинарный классификатор

$$\boldsymbol{a(x) = sign(w, x)}$$

$$sign(w, x) = +1, \text{если}(w, x) > 0$$

и

$$sign(w, x) = -1, \text{если}(w, x) < 0$$

Линейный классификатор

$$a(x) = sign(w, x)$$

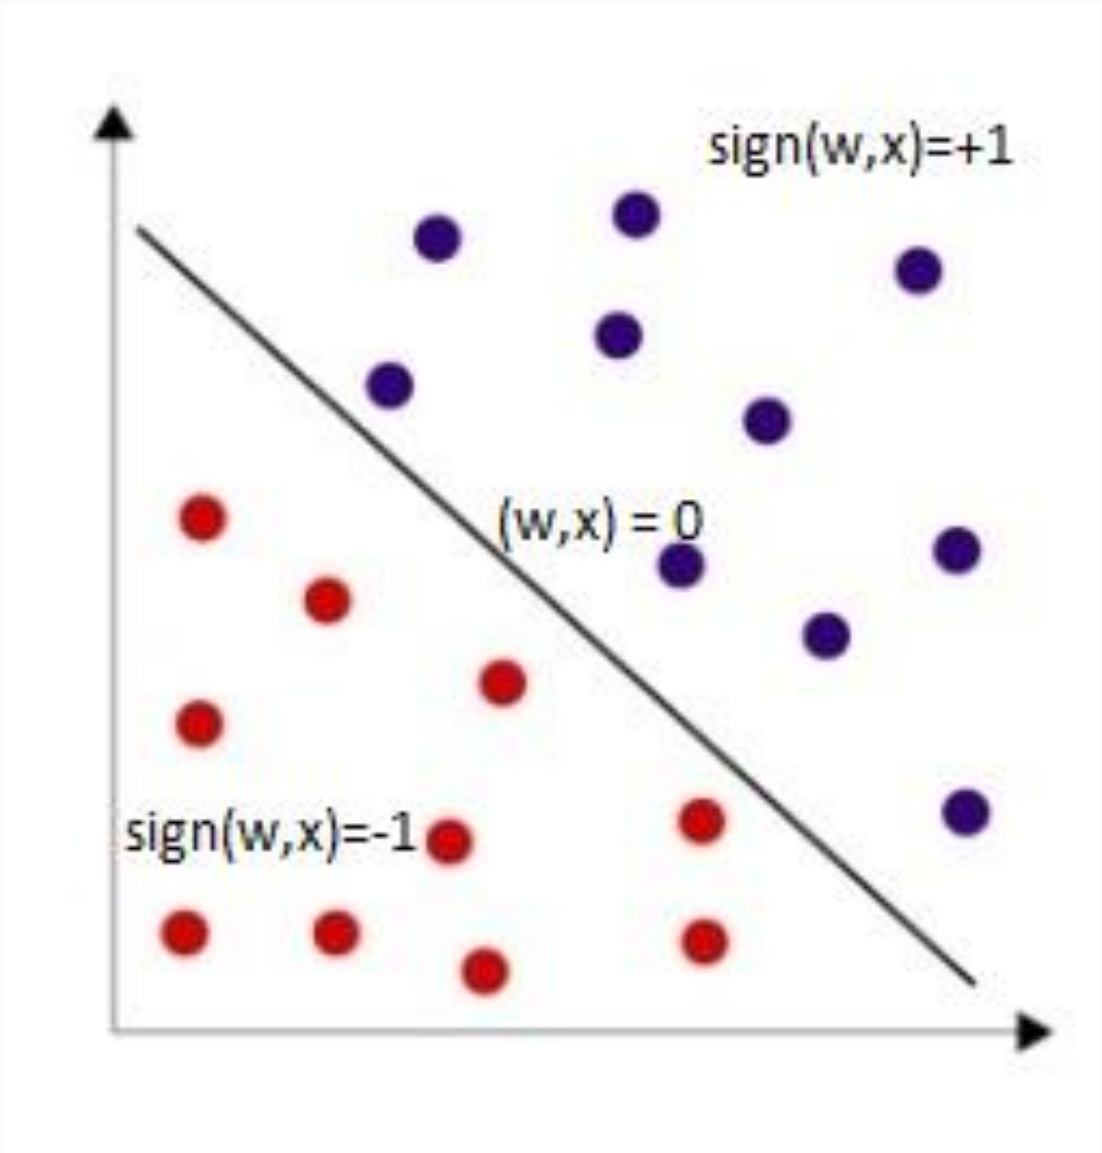

Пример

Признаки пациента:

- x_1 - возраст
- x_2 - температура
- x_3 - показатель давления

Классификатор:

$$a(x) = sign(w_0 + w_1x_1 + w_2x_2 + w_3x_3)$$

4 параметра - w_0, w_1, w_2, w_3

Логистическая регрессия

Логистическая регрессия – это линейный классификатор! Попробуем применить его для решения задачи.

Практика!

https://colab.research.google.com/drive/1sas_HMWThGSiEZvN4hiq-dxU6xLHKks7#scrollTo=z79gbIw0bWJZ

Мягкая классификация

- нам хочется знать не только ответ, но и вероятность ответа

Бинарный линейный классификатор

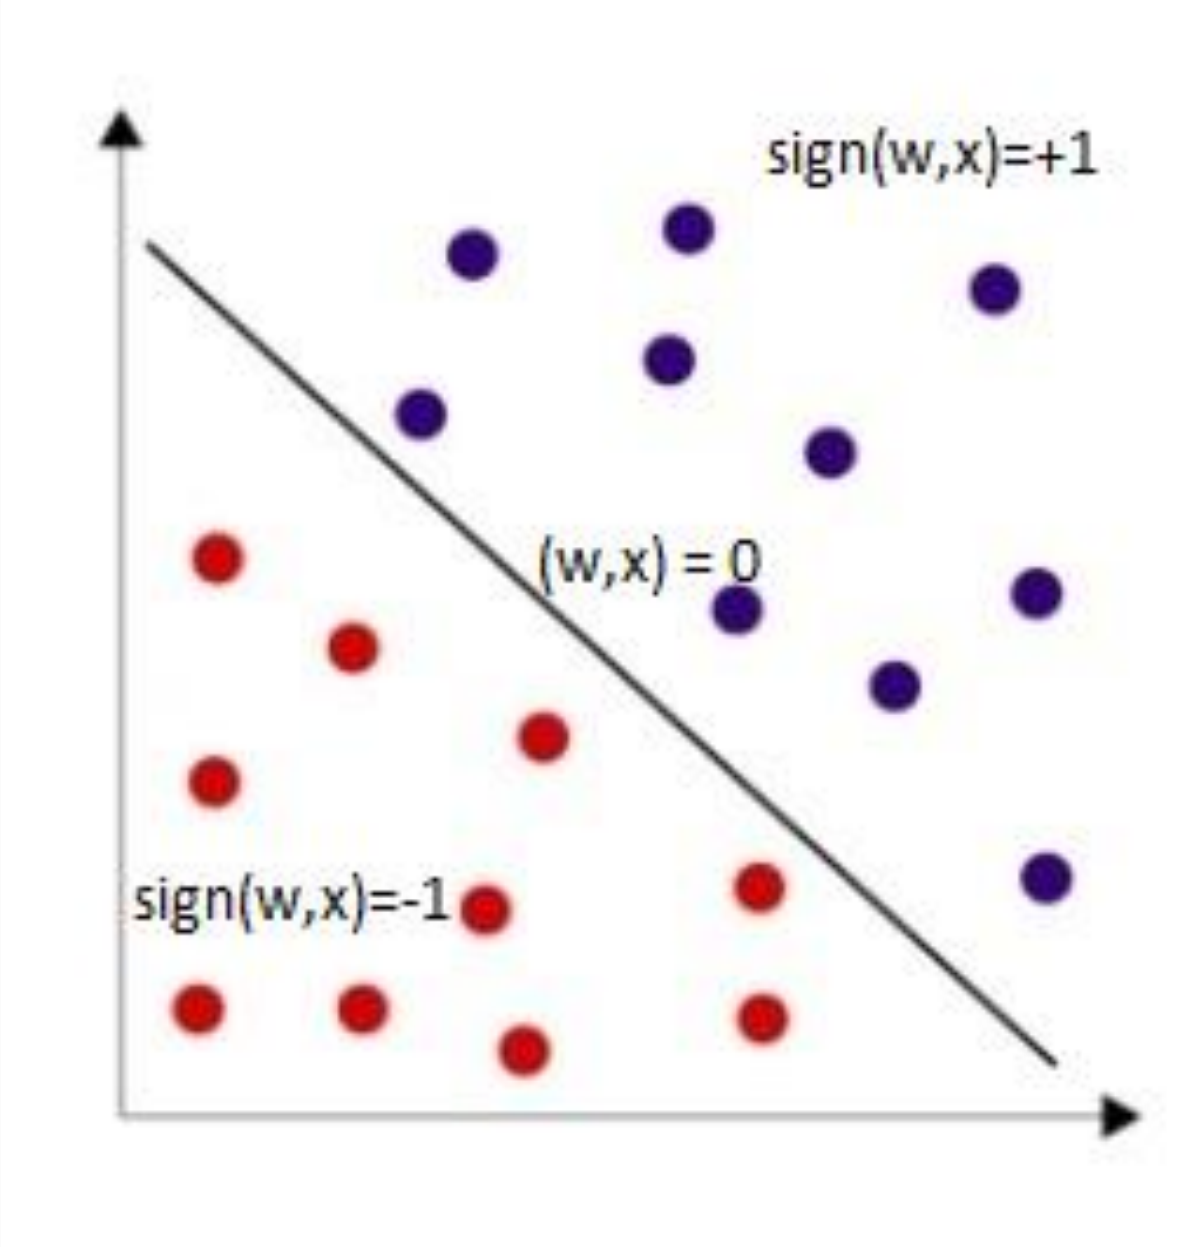

Уверенность классификатора

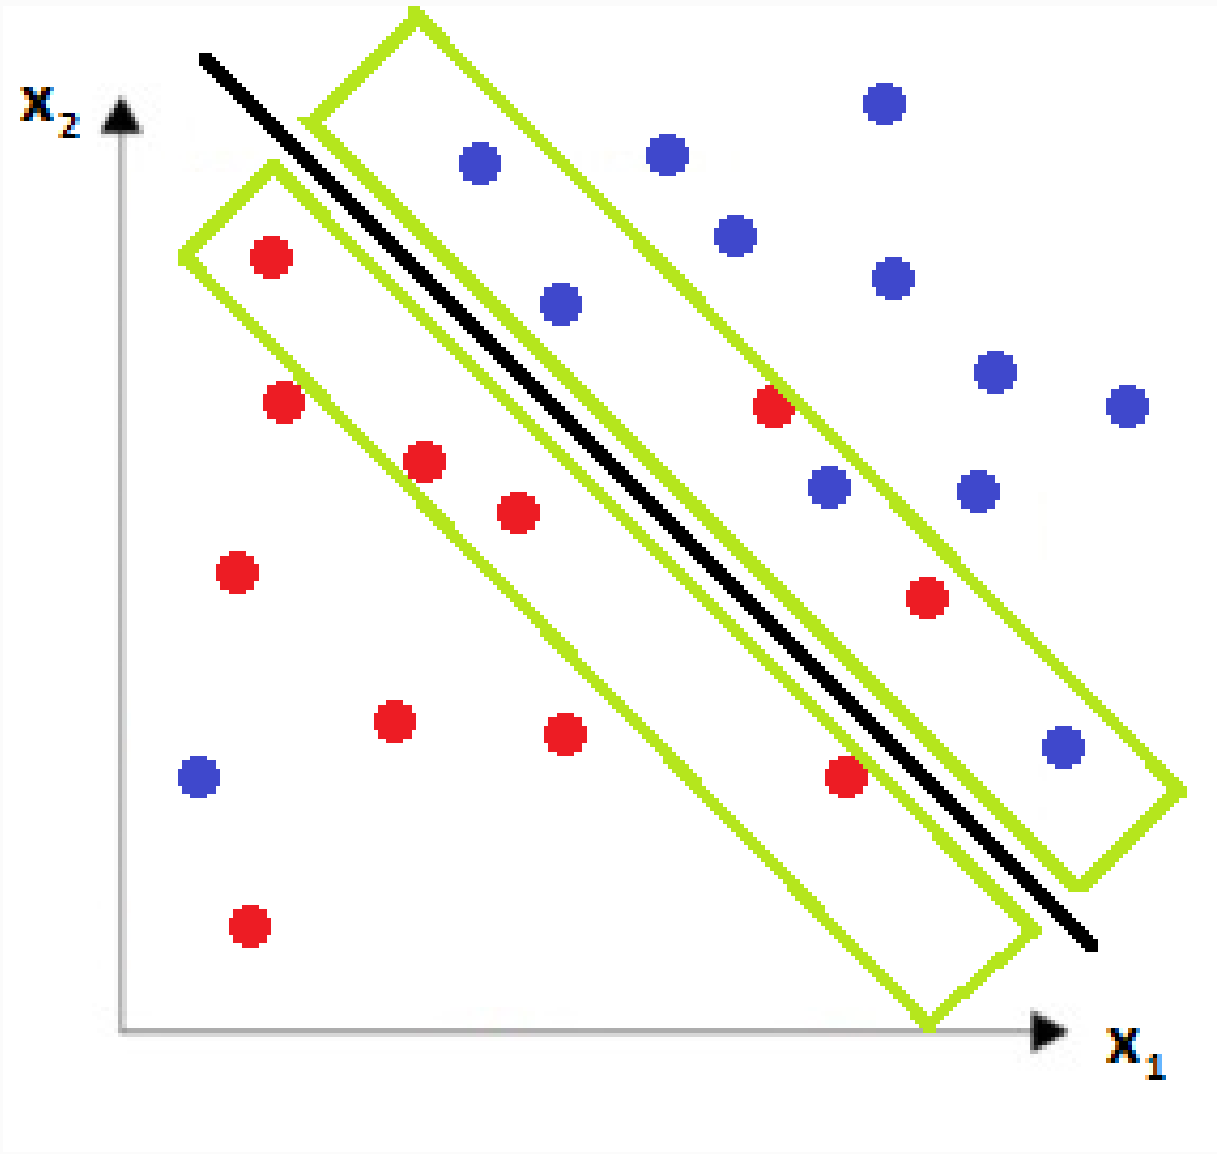

Уверенность классификатора

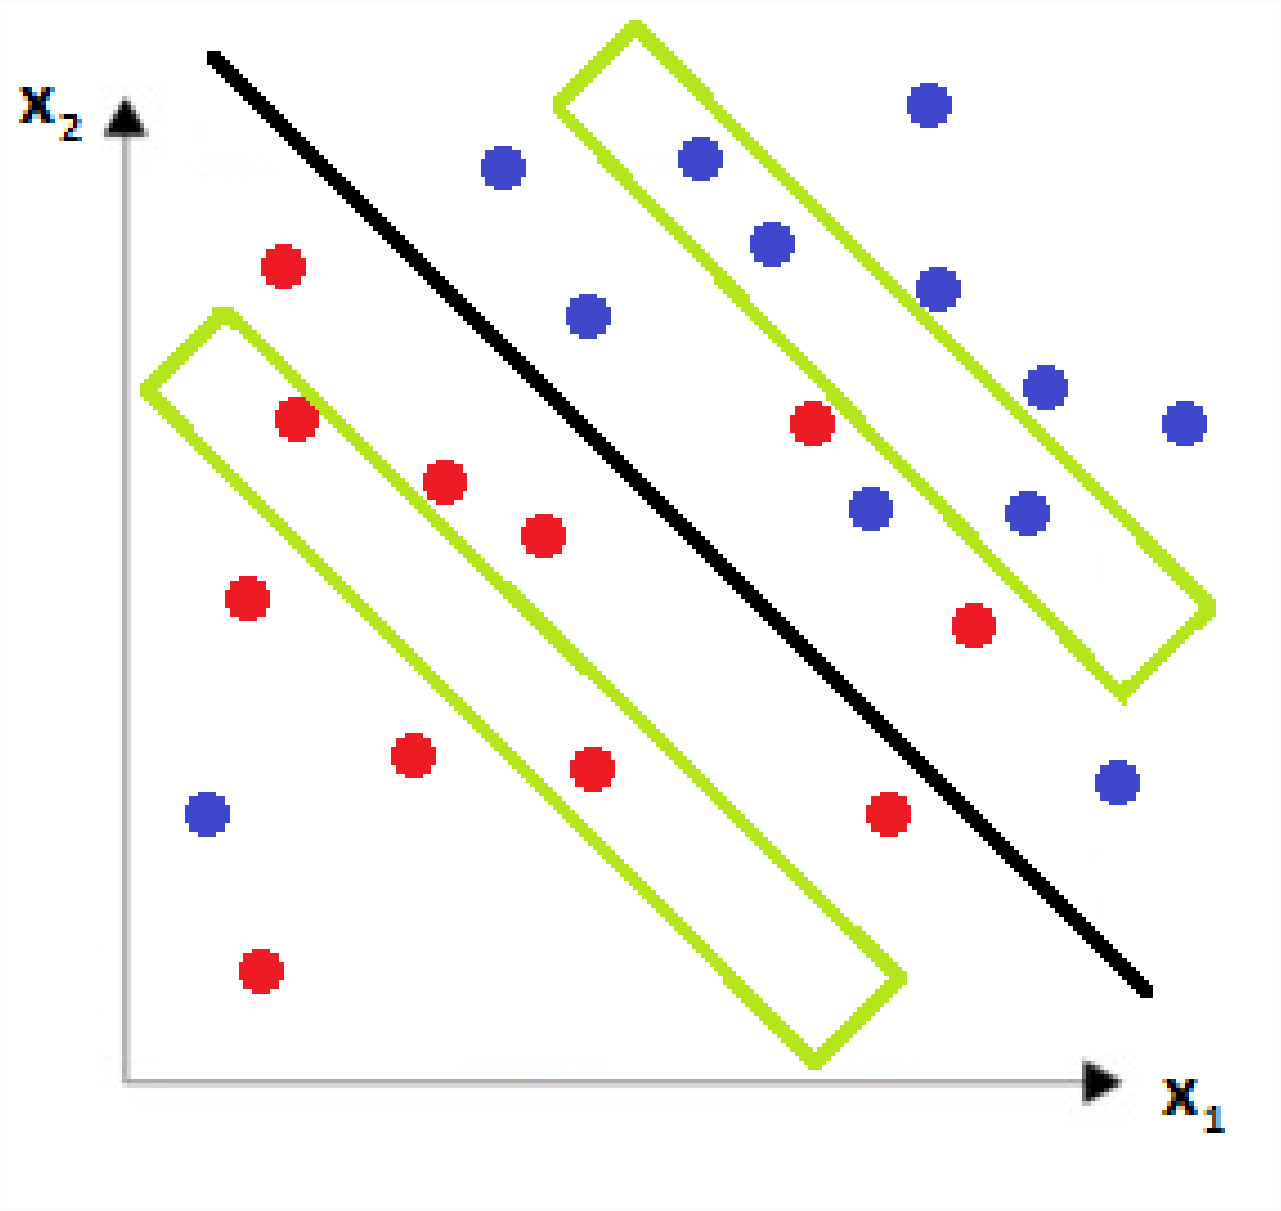

Сигмоида

$$\sigma(x) = \frac{1}{1+e^{-x}}$$

Сигмоида переводит произвольное действительное число (расстояние от объекта до разделяющей границы) в отрезок [0; 1].

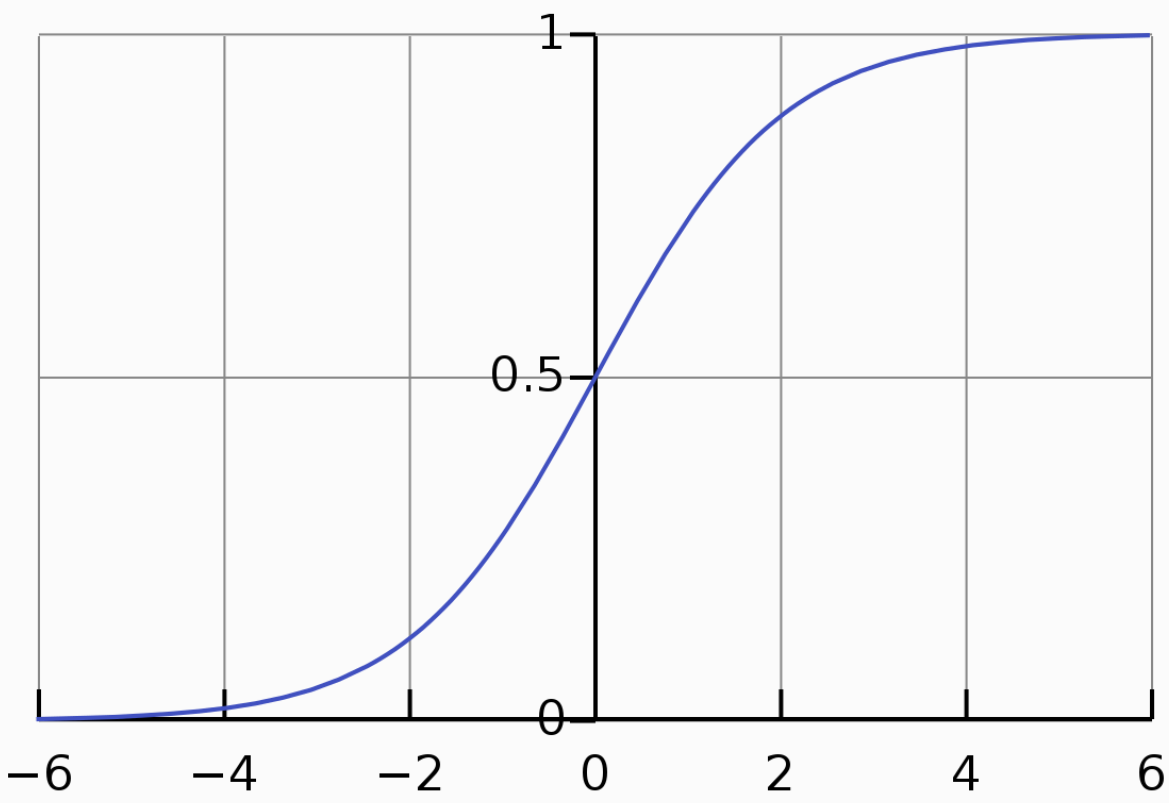

Предсказываем вероятность

$$a(x) = \sigma(w, x) = \frac{1}{1+e^{-(w,x)}}$$

Использование сигмоиды позволяет получить число из отрезка [0; 1].

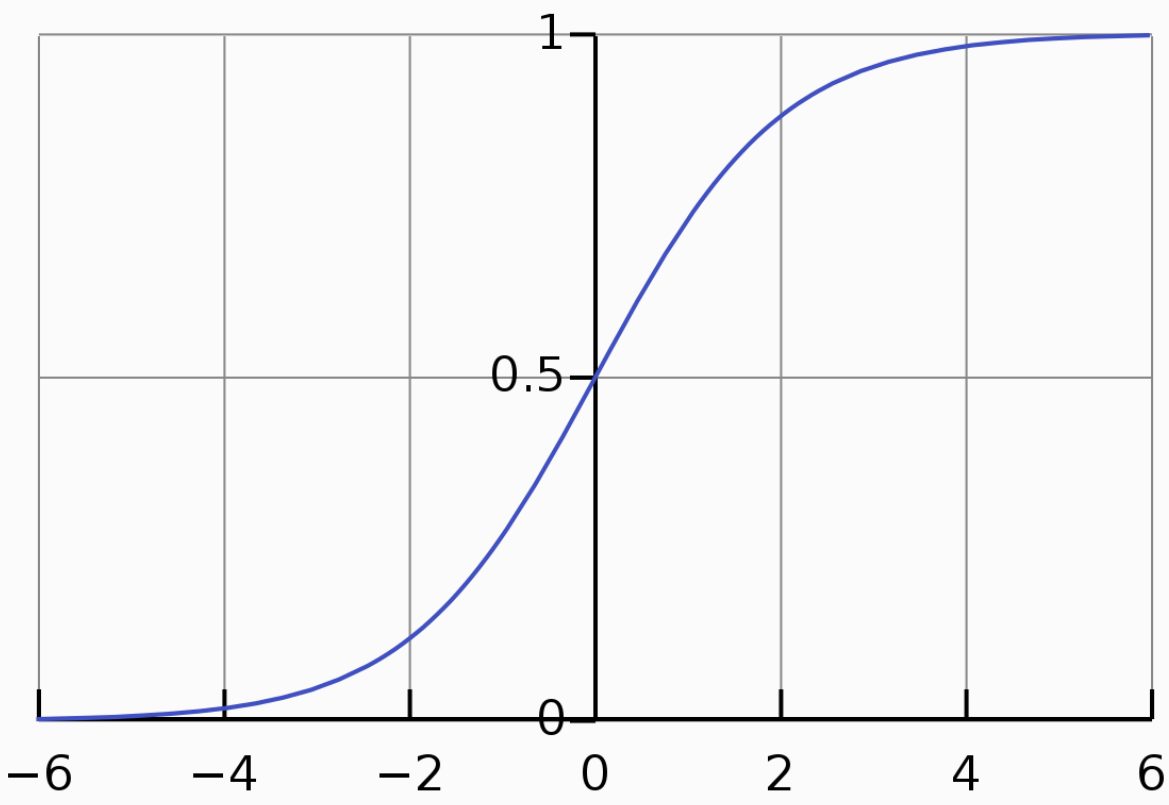

Логистическая регрессия

$$a(x) = \frac{1}{1 + e^{-(w,x)}}$$

Логистическая регрессия – это линейный классификатор, который умеет предсказывать вероятности классов!

Логистическая регрессия для модели оттока

- получаем не только класс (болен пациент или нет), но и вероятность того, что пациент болен
- получаем хорошо интерпретируемую модель, например,

$$a(x) = \sigma(1 + \mathbf{10} \cdot \text{давление} - \mathbf{5} \cdot \text{температура})$$

Пример: предсказание модели

id	Предсказанная вероятность	Правильный ответ	Предсказанный класс
1	0.6	-1	1
2	0.8	1	1
3	0.3	-1	-1
4	0.55	-1	1
5	0.1	-1	-1
6	0.96	1	1
7	0.33	1	-1
8	0.2	-1	-1
9	0.14	-1	-1
10	0.88	1	1

Практика!

https://colab.research.google.com/drive/1sas_HMWThGSiEZvN4hiq-dxU6xLHKks7#scrollTo=z79gbIw0bWJZ

Accuracy

- **Accuracy** – это доля правильных ответов алгоритма

Accuracy = 0.7

id	Предсказанная вероятность	Правильный ответ	Предсказанный класс
1	0.6	-1	**1**
2	0.8	1	1
3	0.3	-1	-1
4	0.55	-1	**1**
5	0.1	-1	-1
6	0.96	1	1
7	0.33	1	**-1**
8	0.2	-1	-1
9	0.14	-1	-1
10	0.88	1	1

Accuracy

- 1000 объектов:

950 – не мошенники (класс 0)
50 – мошенники (класс +1)

- Модель: a(x) = 0

Accuracy?

Accuracy

- 1000 объектов:

950 – не мошенники (класс 0)
50 – мошенники (класс +1)

- Модель: a(x) = 0

Accuracy = 0.95

Если классы несбалансированы, то accuracy не надо использовать!

Матрица ошибок

Confusion Matrix

Actual / ***Predict***	0	1
0	TN	FN
1	FP	TP

ROC-AUC: интуиция

- Пример:

p	класс
0.5	0
0.1	0
0.25	0
0.6	1
0.2	1
0.3	1
0.0	0

p	класс
0.6	1
0.5	0
0.3	1
0.25	0
0.2	1
0.1	0
0.0	0

ROC-AUC: алгоритм

- Нарисуем квадрат 1 на 1.
- Горизонтальную сторону квадрата разобъем на равные отрезки, число которых равно числу 0 в данных
- Вертикальную сторону разобъем на равные отрезки, число которых равно числу 1

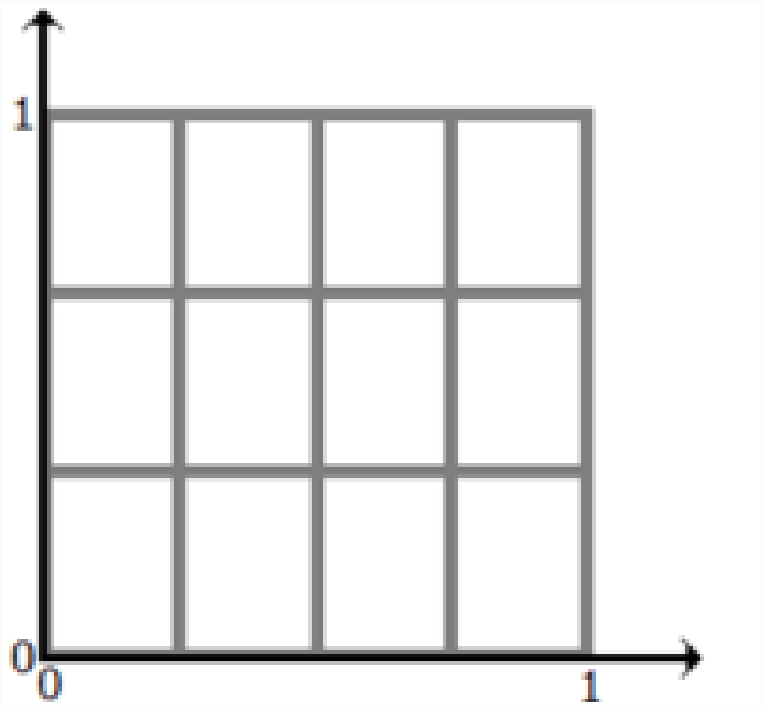

ROC-AUC: алгоритм

- Нарисуем квадрат 1 на 1.
- Горизонтальную сторону квадрата разобъем на равные отрезки, число которых равно числу 0 в данных
- Вертикальную сторону разобъем на равные отрезки, число которых равно числу 1

p	класс
0.6	1
0.5	0
0.3	1
0.25	0
0.2	1
0.1	0
0.0	0

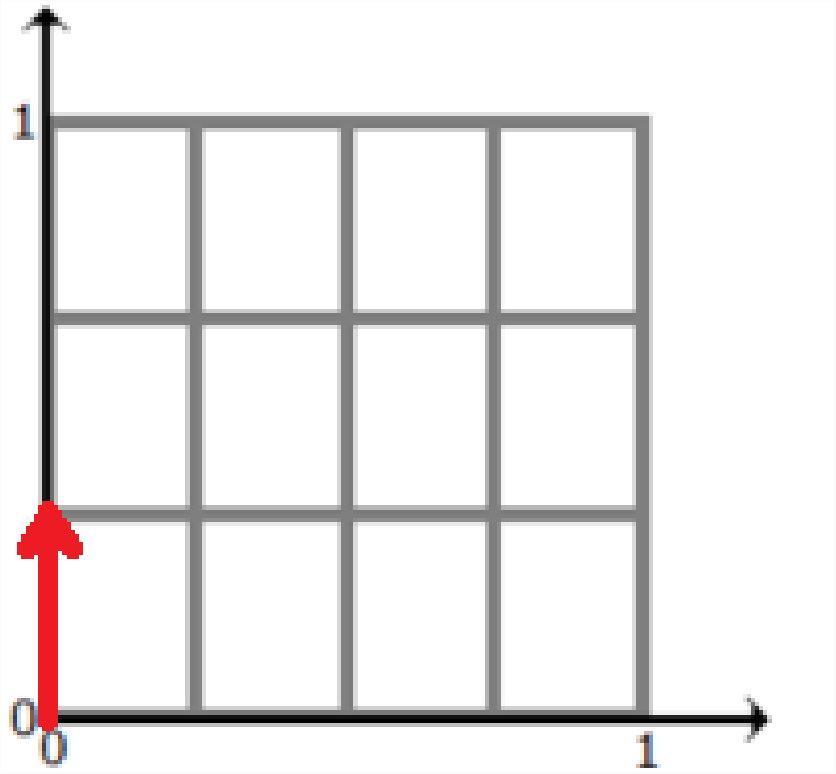

ROC-AUC: алгоритм

- Нарисуем квадрат 1 на 1.
- Горизонтальную сторону квадрата разобъем на равные отрезки, число которых равно числу 0 в данных
- Вертикальную сторону разобъем на равные отрезки, число которых равно числу 1

p	класс
0.6	1
0.5	0
0.3	1
0.25	0
0.2	1
0.1	0
0.0	0

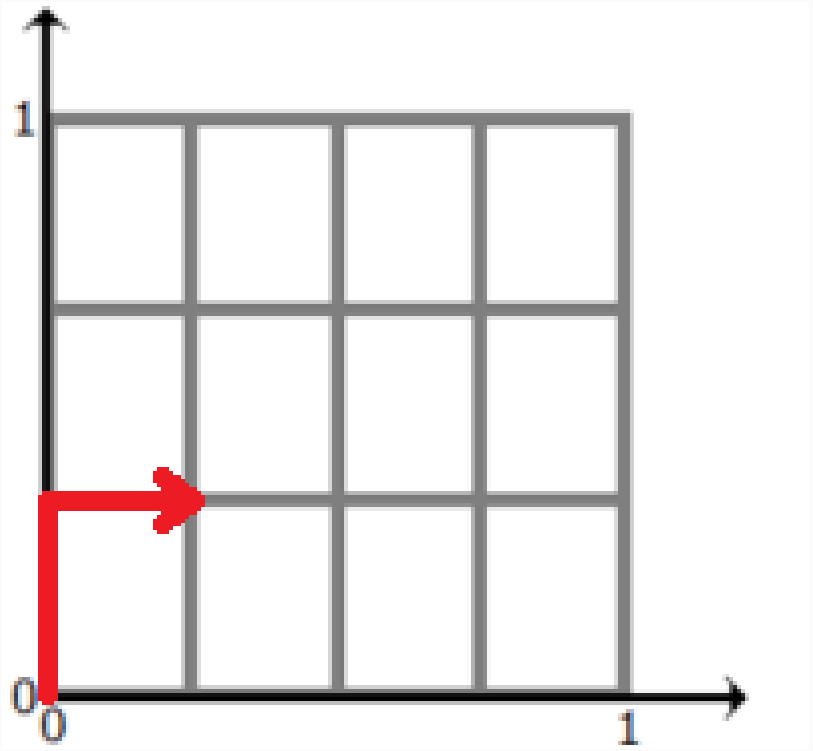

ROC-AUC: алгоритм

- Нарисуем квадрат 1 на 1.
- Горизонтальную сторону квадрата разобъем на равные отрезки, число которых равно числу 0 в данных
- Вертикальную сторону разобъем на равные отрезки, число которых равно числу 1

p	класс
0.6	1
0.5	0
0.3	1
0.25	0
0.2	1
0.1	0
0.0	0

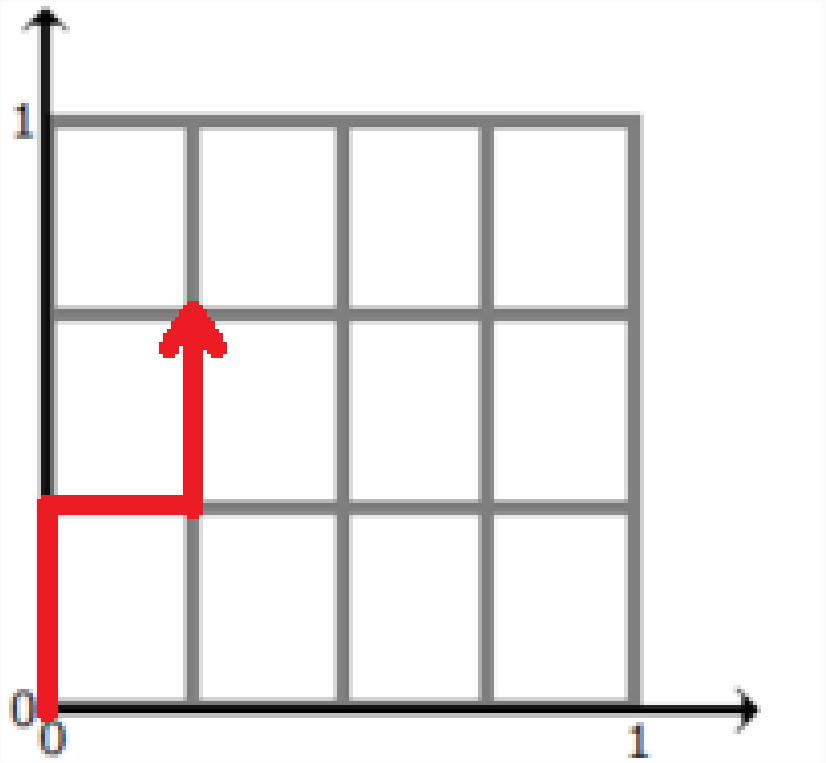

ROC-AUC: алгоритм

- Пойдем по отсортированной таблице по столбцу класс сверху вниз
- Будем стартовать из точки (0,0) на квадрате. И если мы встречаем 1, сдвигаемся на одну клеточку вверх, а если 0 - то вправо
- В итоге мы придём в точку (1,1).

p	класс
0.6	1
0.5	0
0.3	1
0.25	0
0.2	1
0.1	0
0.0	0

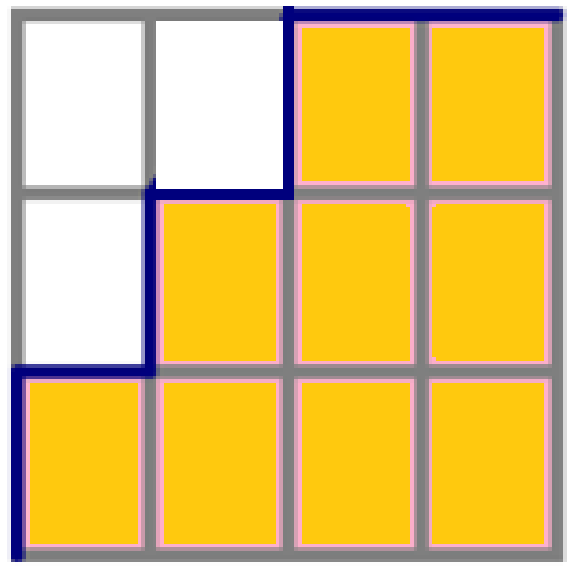

Полученная кривая называется ROC-кривой, а метрика, равная площади под ней - AUC-ROC.

ROC-AUC: примеры

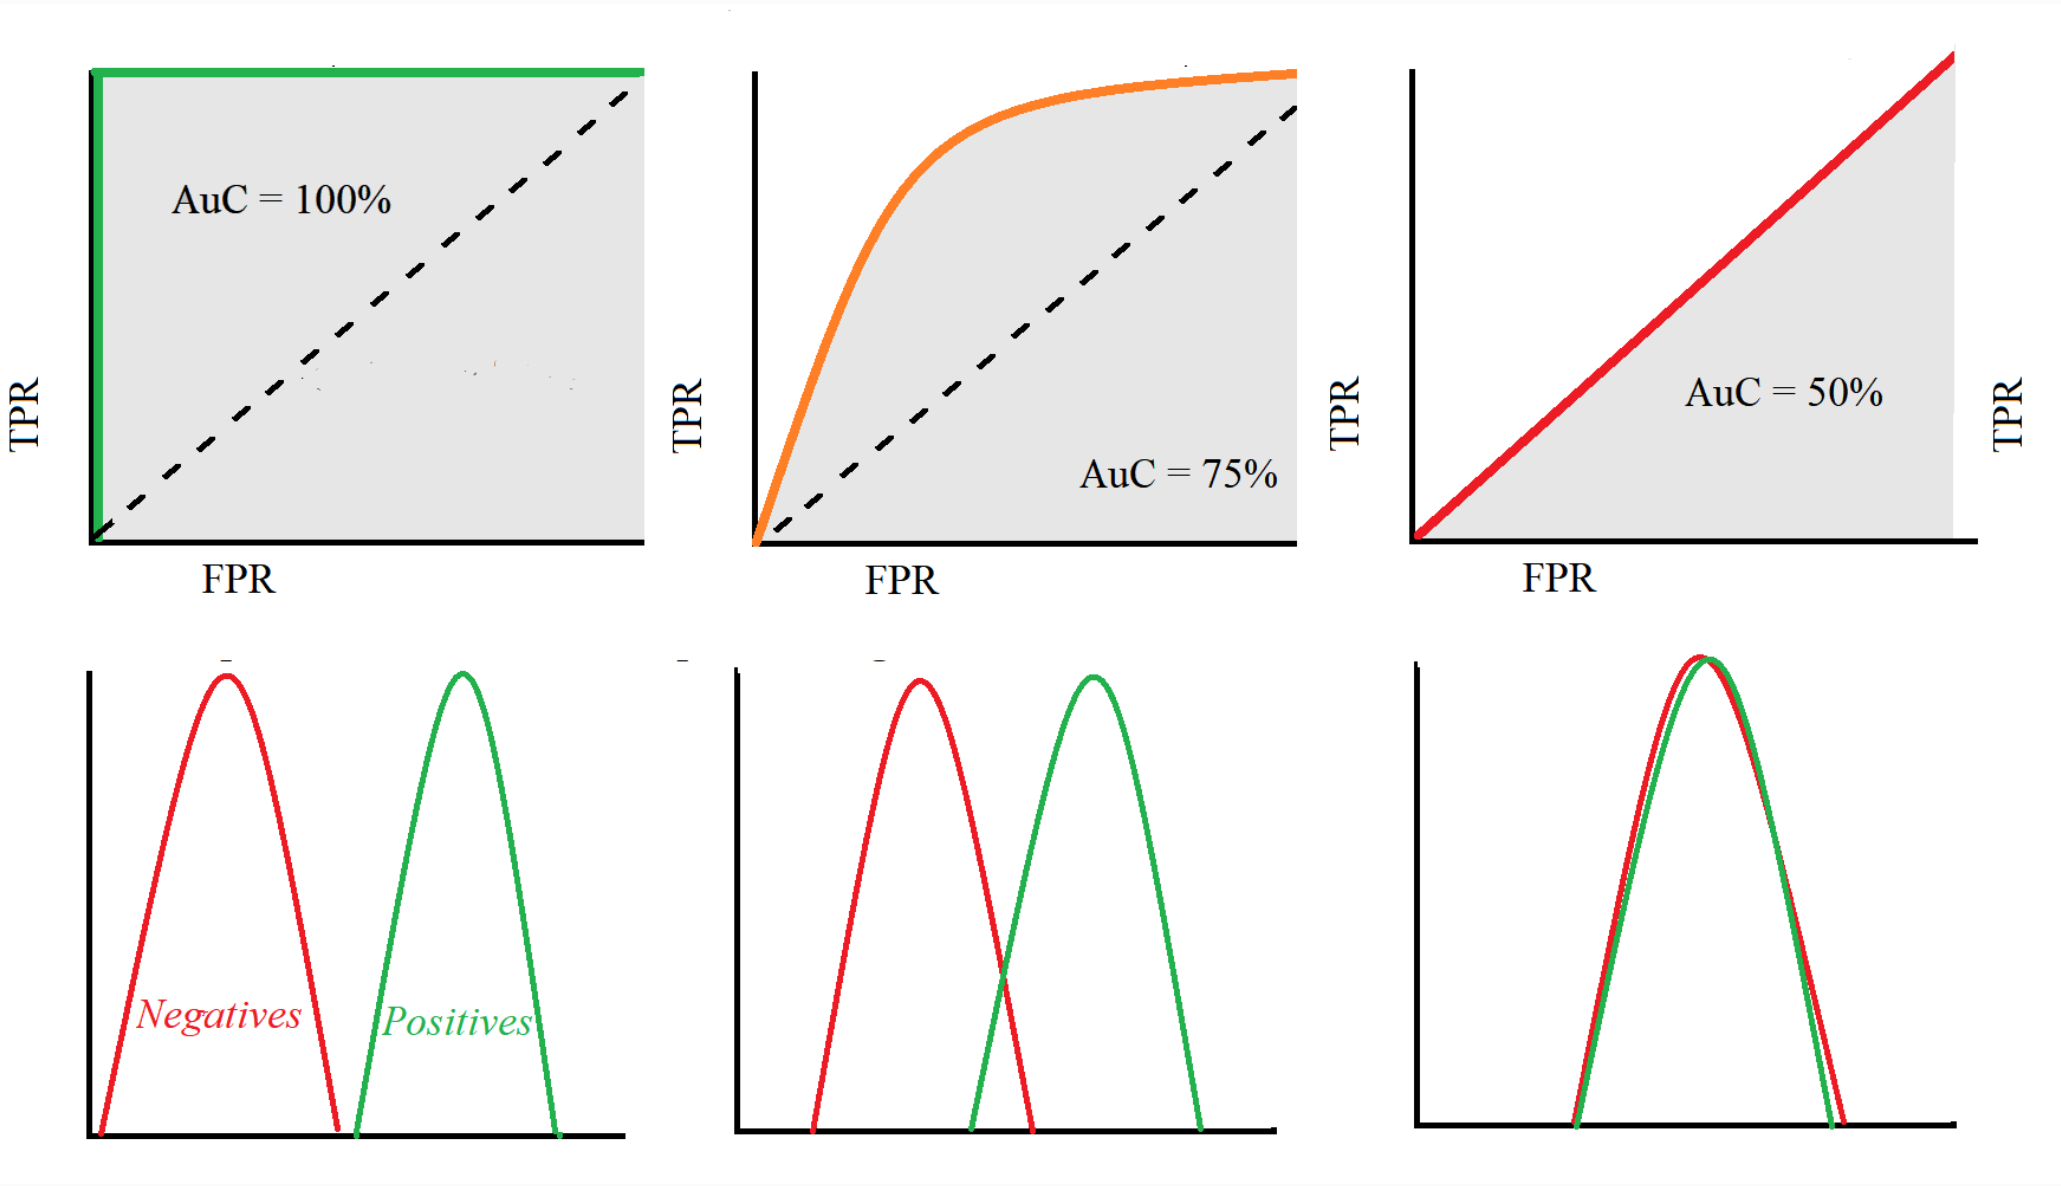

Практика!

https://colab.research.google.com/drive/1sas_HMWThGSiEZvN4hiq-dxU6xLHKks7#scrollTo=z79gbIw0bWJZ